第六章 Part2 :高速缓存存储器

- 教　师：　郑贵滨
- 听觉智能研究中心
- 哈尔滨工业大学，计算机科学与技术学院

主要内容

- 高速缓存存储器组织结构和操作
- 高速缓存对程序性能的影响
  - 存储器山
  - 重新排列循环以提高空间局部性
  - 使用分块来提高时间局部性

存储器层次结构

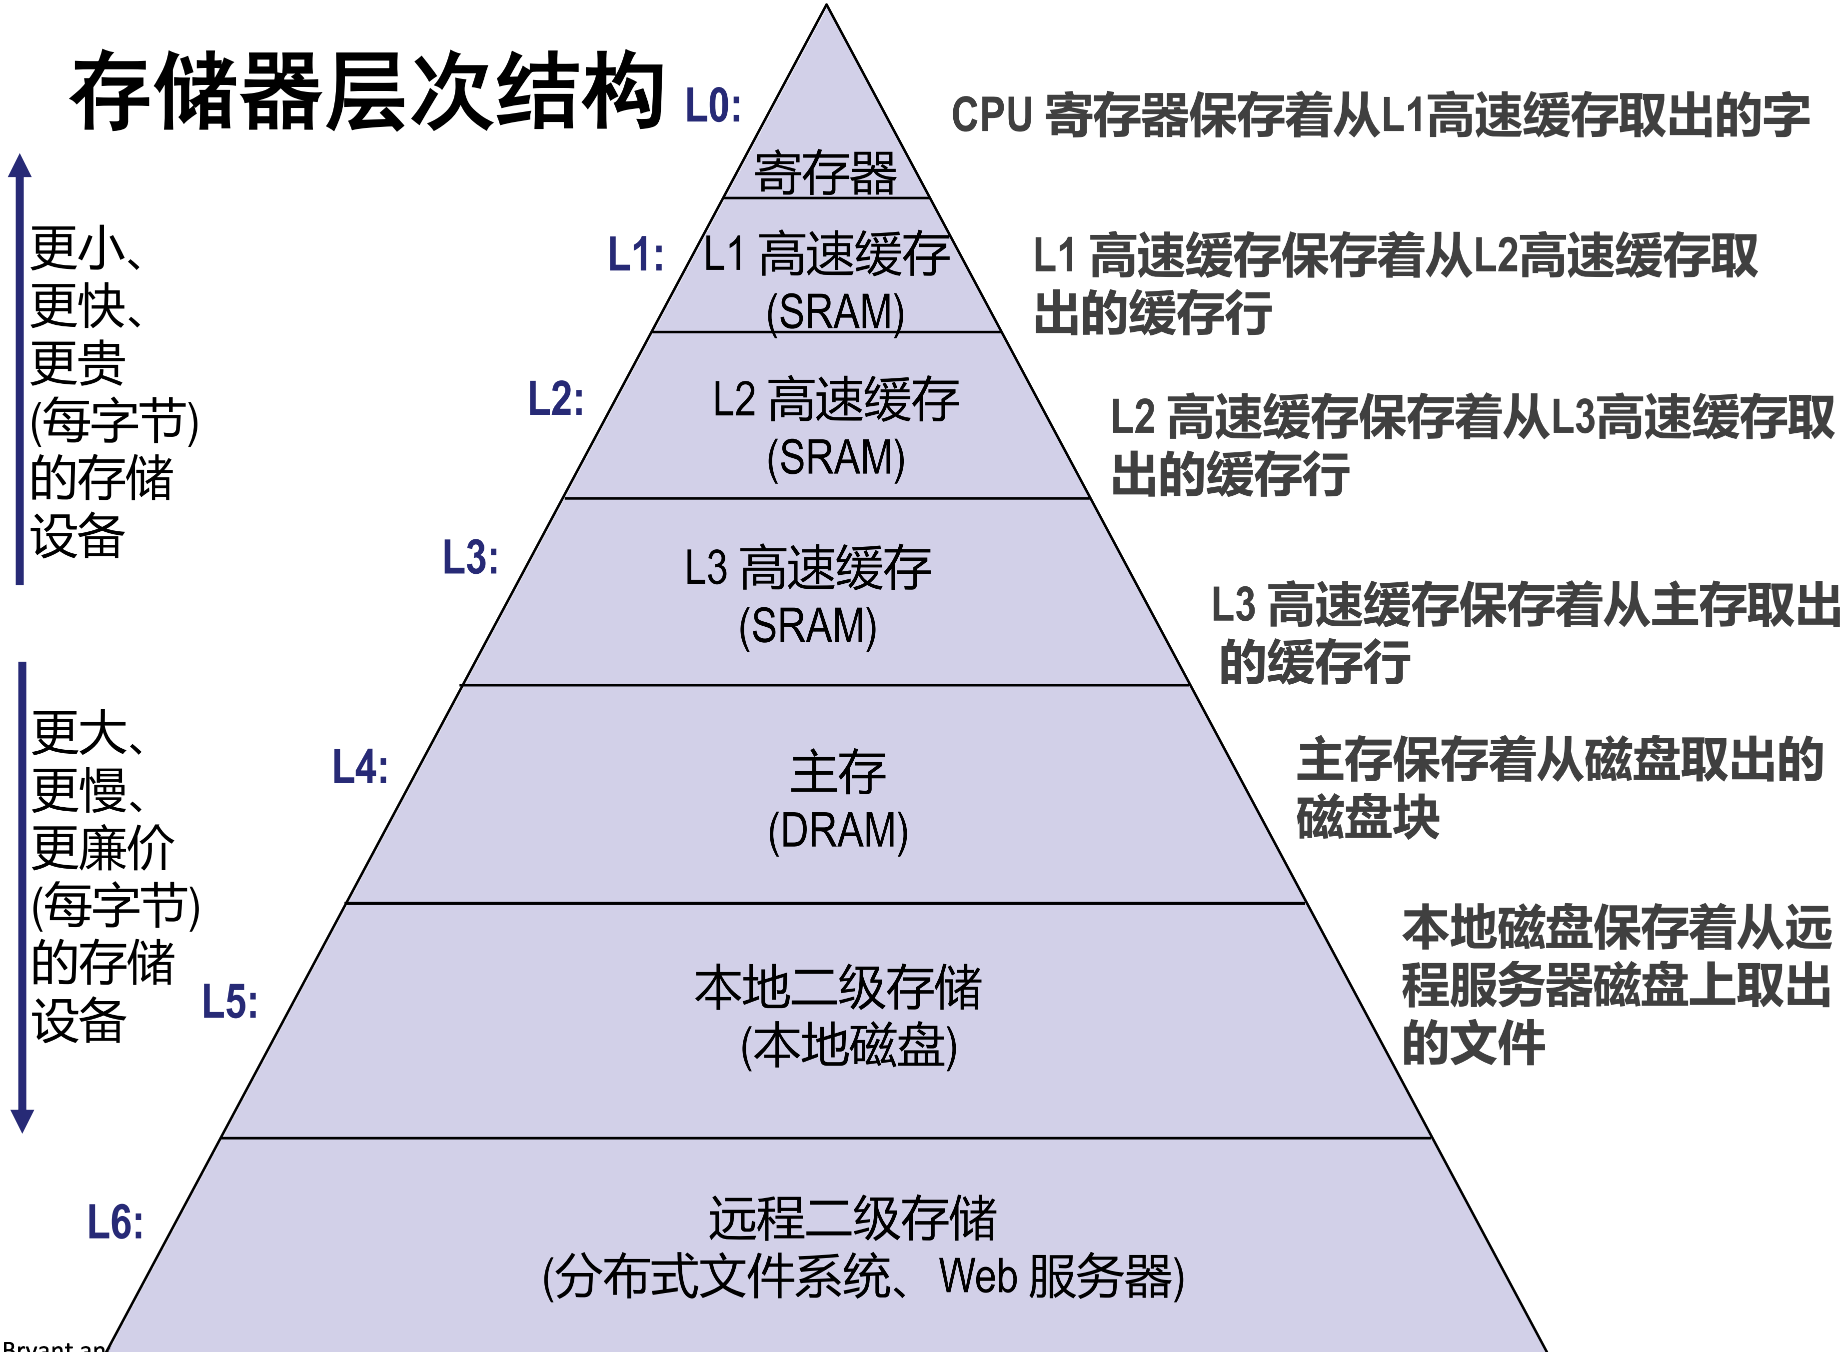
L0:
寄存器
CPU 寄存器保存着从L1高速缓存取出的字
L1:
L1 高速缓存
(SRAM)
L1 高速缓存保存着从L2高速缓存取出的缓存行
L2:
L2 高速缓存
(SRAM)
L2 高速缓存保存着从L3高速缓存取出的缓存行
L3:
L3 高速缓存
(SRAM)
L3 高速缓存保存着从主存取出的缓存行
L4:
主存
(DRAM)
主存保存着从磁盘取出的磁盘块
L5:
本地二级存储
(本地磁盘)
本地磁盘保存着从远程服务器磁盘上取出的文件
L6:
远程二级存储
(分布式文件系统、Web 服务器)
更小、
更快、
更贵
(每字节)
的存储
设备
更大、
更慢、
更廉价
(每字节)
的存储
设备

高速缓存存储器

- 高速缓存存储器是小型的、快速的基于SRAM的存储器是在硬件中自动管理的
  - 保存经常访问主存的块
- CPU 首先查找缓存中的数据
- 典型的系统结构

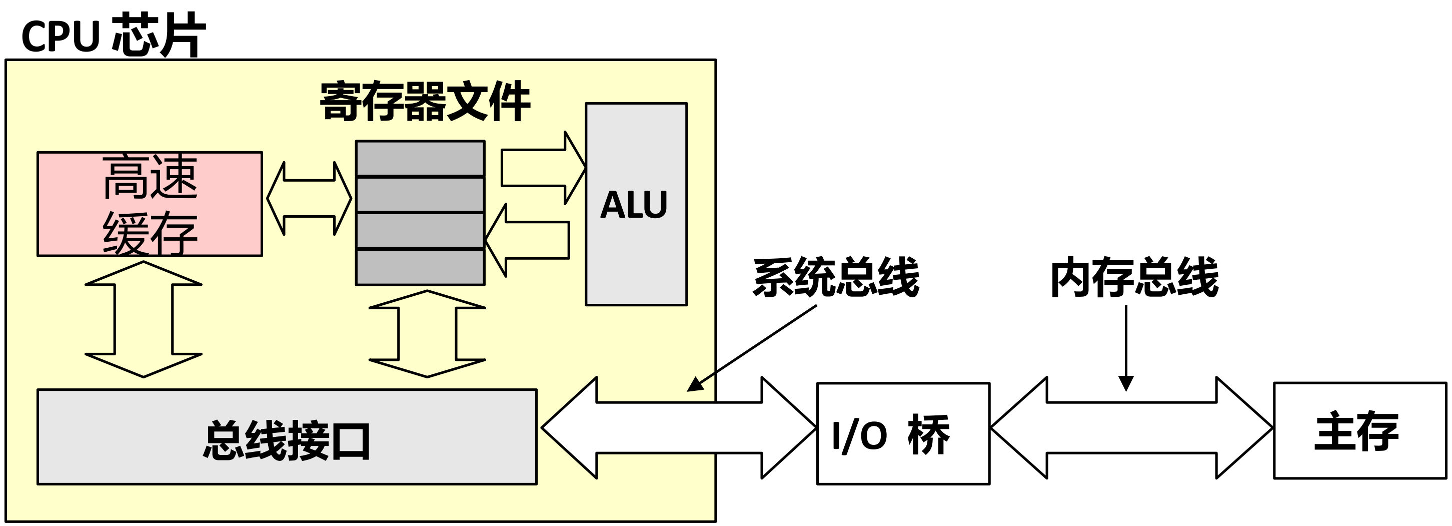

回顾：现代CPU设计

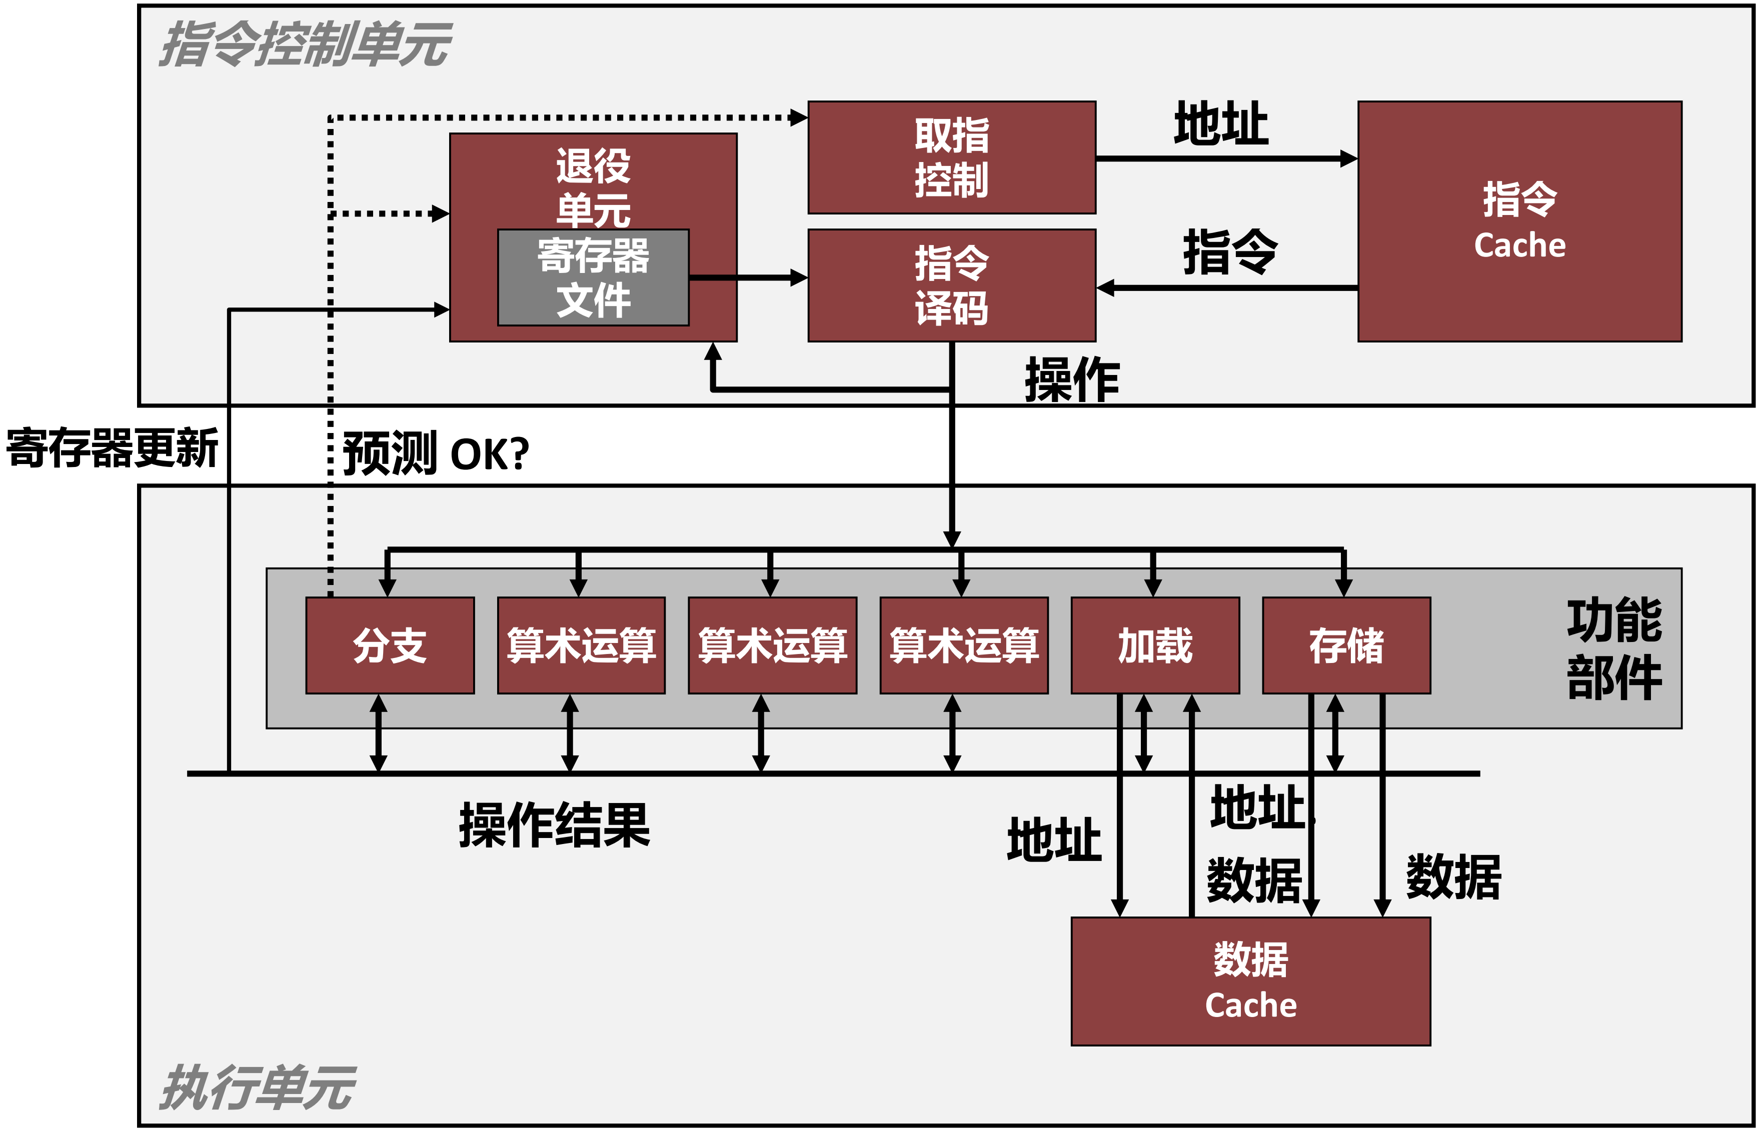
指令控制单元
取指
控制
地址
指令
Cache
退役
单元
寄存器
文件
指令
译码
指令
操作
寄存器更新
预测 OK?
分支
算术运算
算术运算
算术运算
加载
存储
功能
部件
操作结果
地址
地址,
数据
数据
数据
Cache
执行单元

实例

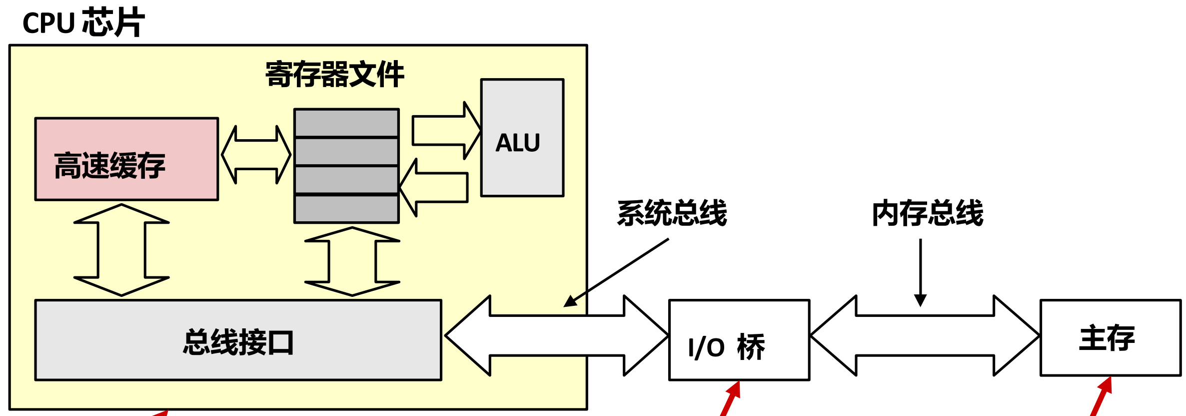

台式机 PC

Source: Dell

CPU (Intel Core i7)

Source: PC Magazine

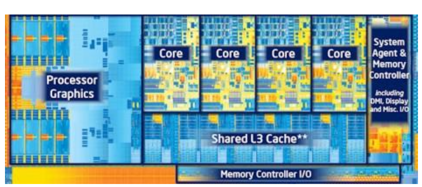

Source: techreport.com

主板

Source: Dell

主存 (DRAM)

Source: Dell

实例(Cont.)

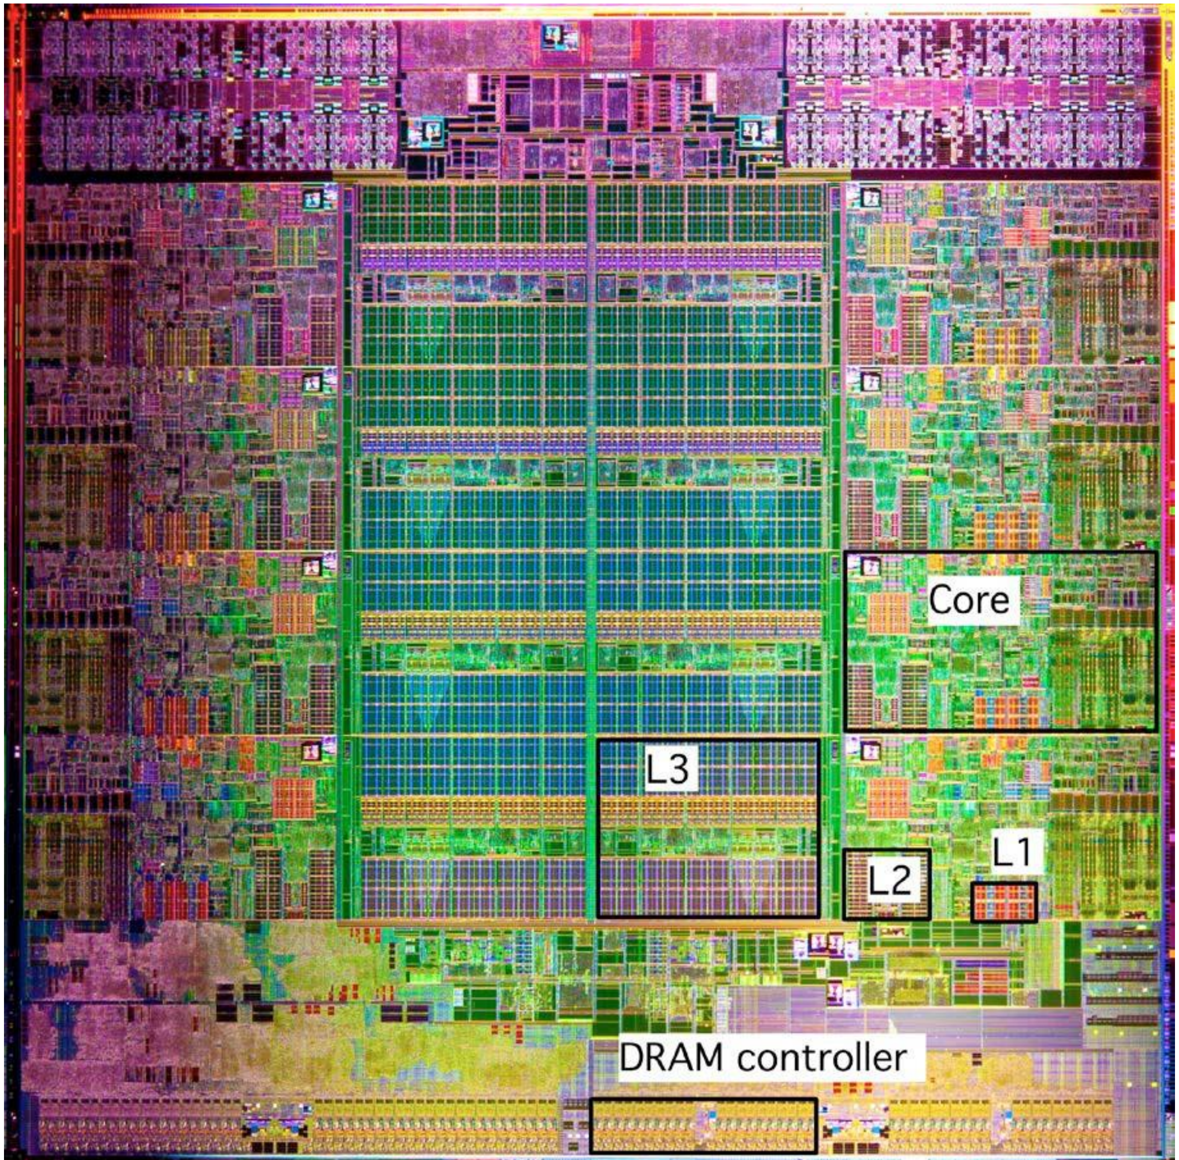

Intel Sandy Bridge Processor Die

L1: 32KB 指令 + 32KB 数据
L2: 256KB
L3: 3–20MB

通用的高速缓存存储器组织结构(S, E, B)

高速缓存大小C = S x E x B 数据字节

高速缓存读

- 定位组
- 定位行：检查集合中的任何行是否有匹配的标记
  是+行有效——命中
- 定位数据：从块偏移开始的数据

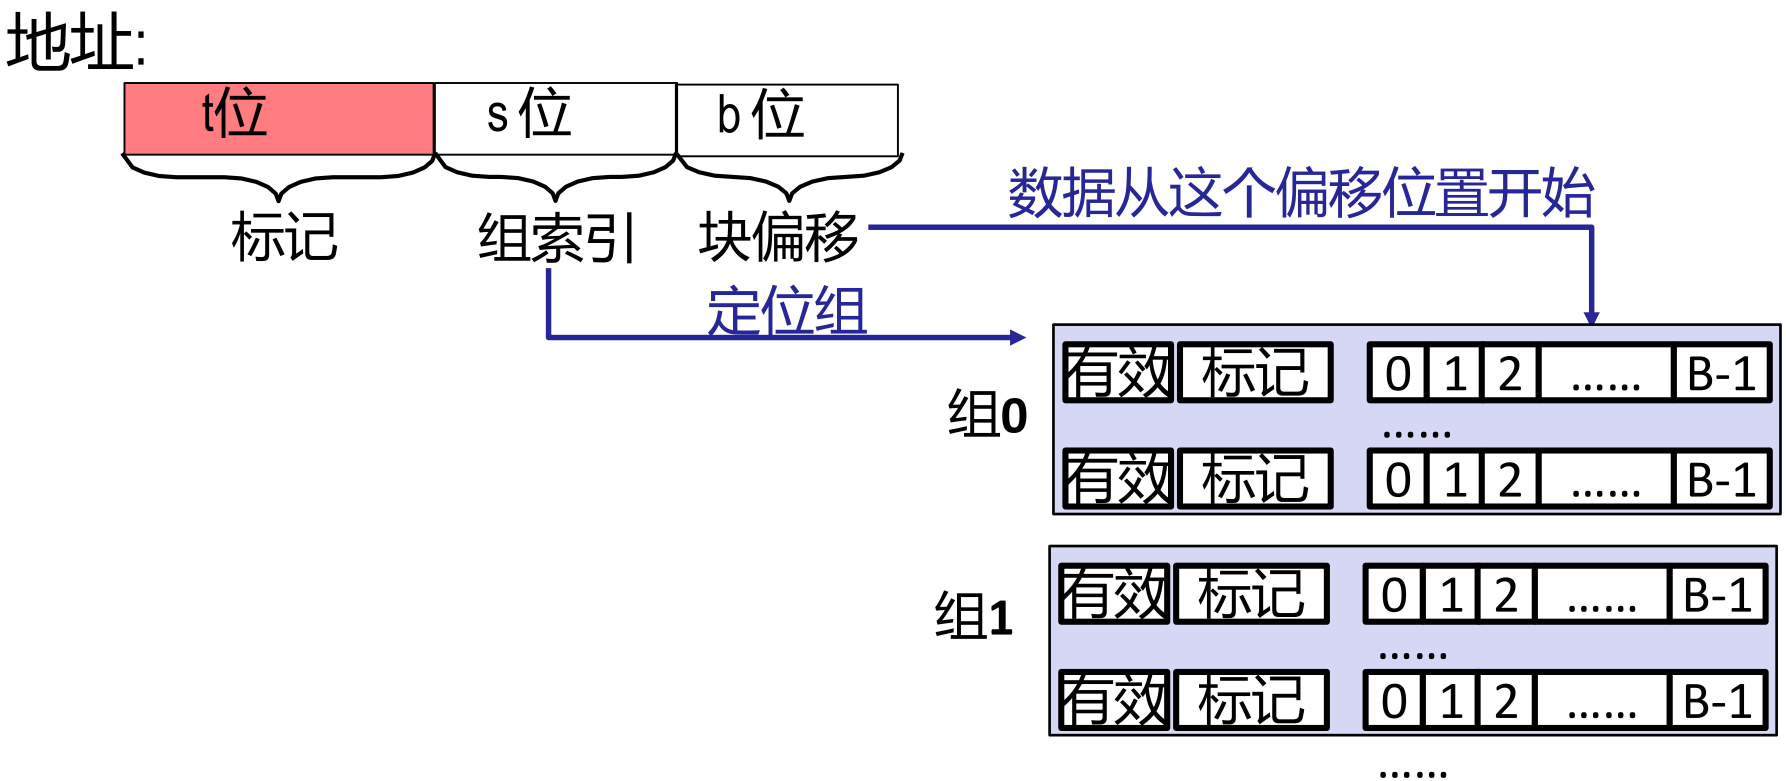

1、直接映射高速缓存 (E = 1)

- 直接映射: 每一组只有一行

假设: 缓存块大小为8字节

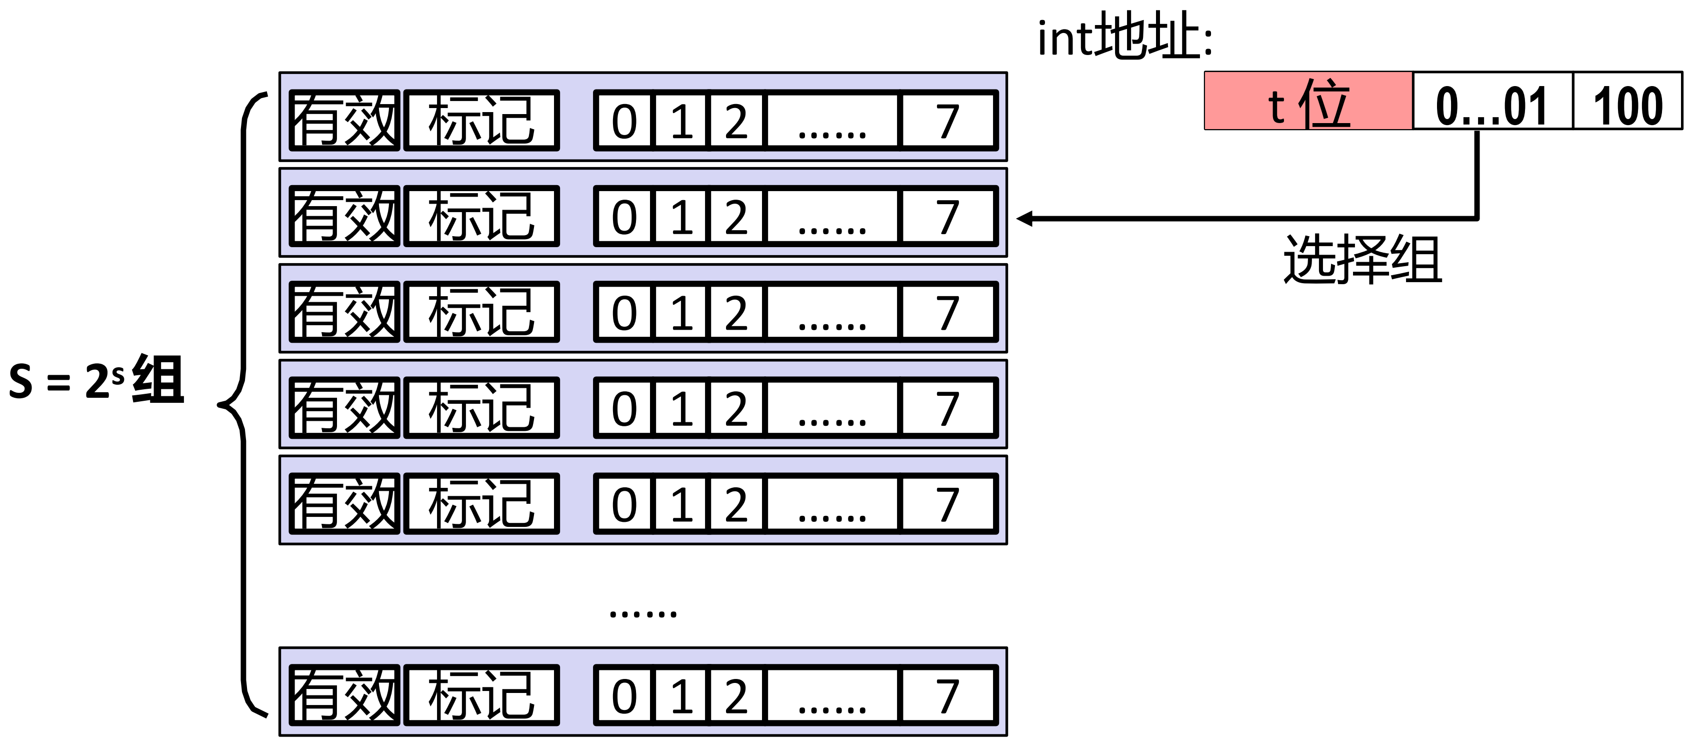

方式1：直接映射高速缓存 (E = 1)

- 直接映射: 每一组只有一行

假设: 缓存块大小为8字节

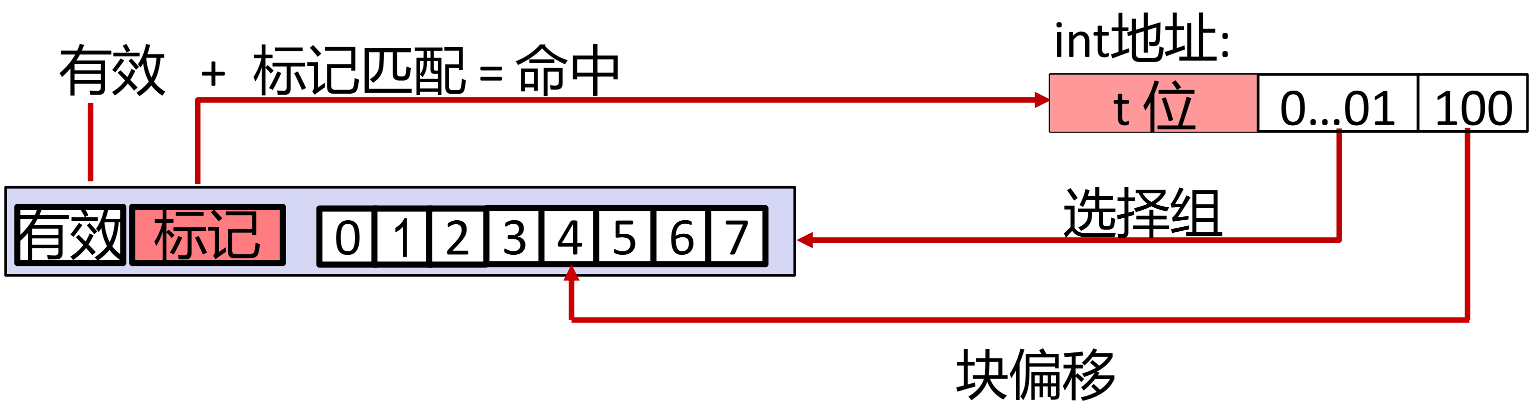

方式1：直接映射高速缓存 (E = 1)

- 直接映射: 每一组只有一行

假设: 缓存块大小为8字节

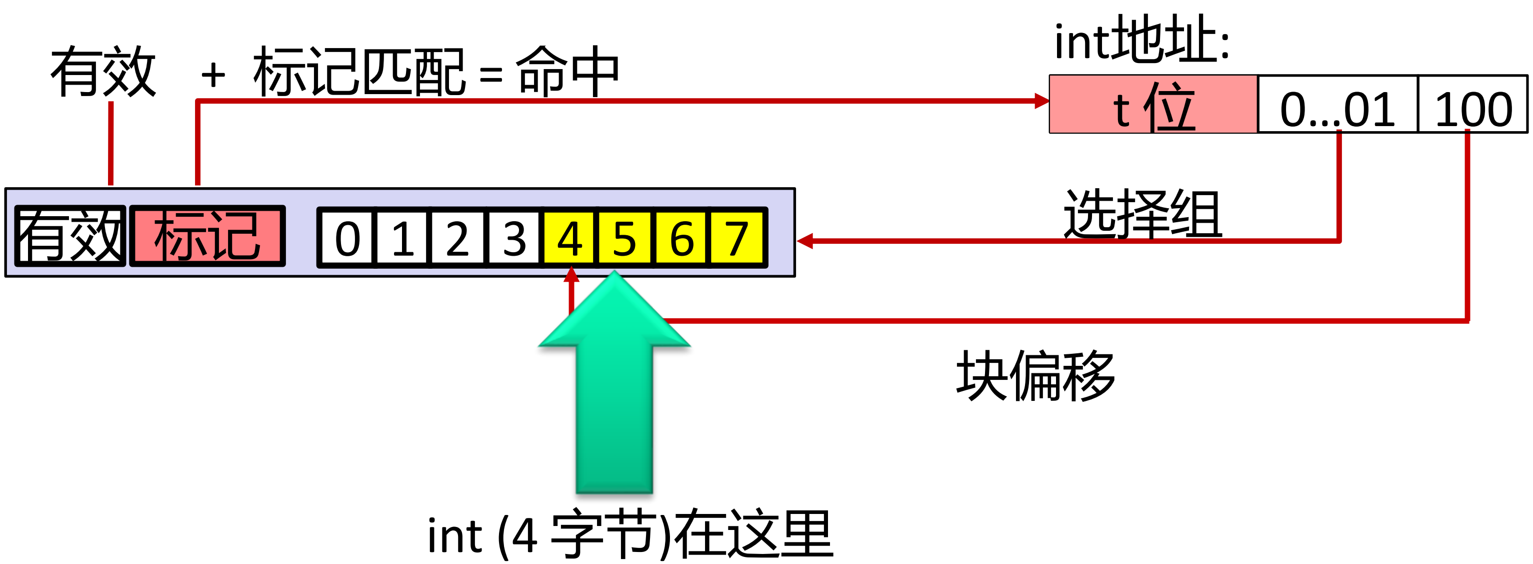

如果标记不匹配: 旧的行被驱逐、替换

直接映射高速缓存模拟

t=1	s=2	b=1
x	xx	x

M=16 字节 (4-位 地址), B=2 字节/块, S=4 组, E=1 块/组

地址跟踪(读, 每次读一个字节):

0	$[0\underline{00}0_2]$,	不命中
1	$[0\underline{00}1_2]$,	命中
7	$[0\underline{11}1_2]$,	不命中
8	$[1\underline{00}0_2]$,	不命中
0	$[0\underline{00}0_2]$	不命中

	v	标记	块
组0	1	0	M[0-1]
组1	0	?	?
组2	0	?	?
组3	1	0	M[6-7]

方式2： E-路组相联高速缓存 (E = 2)

E = 2: 每组两行
假设:缓存块大小为8字节

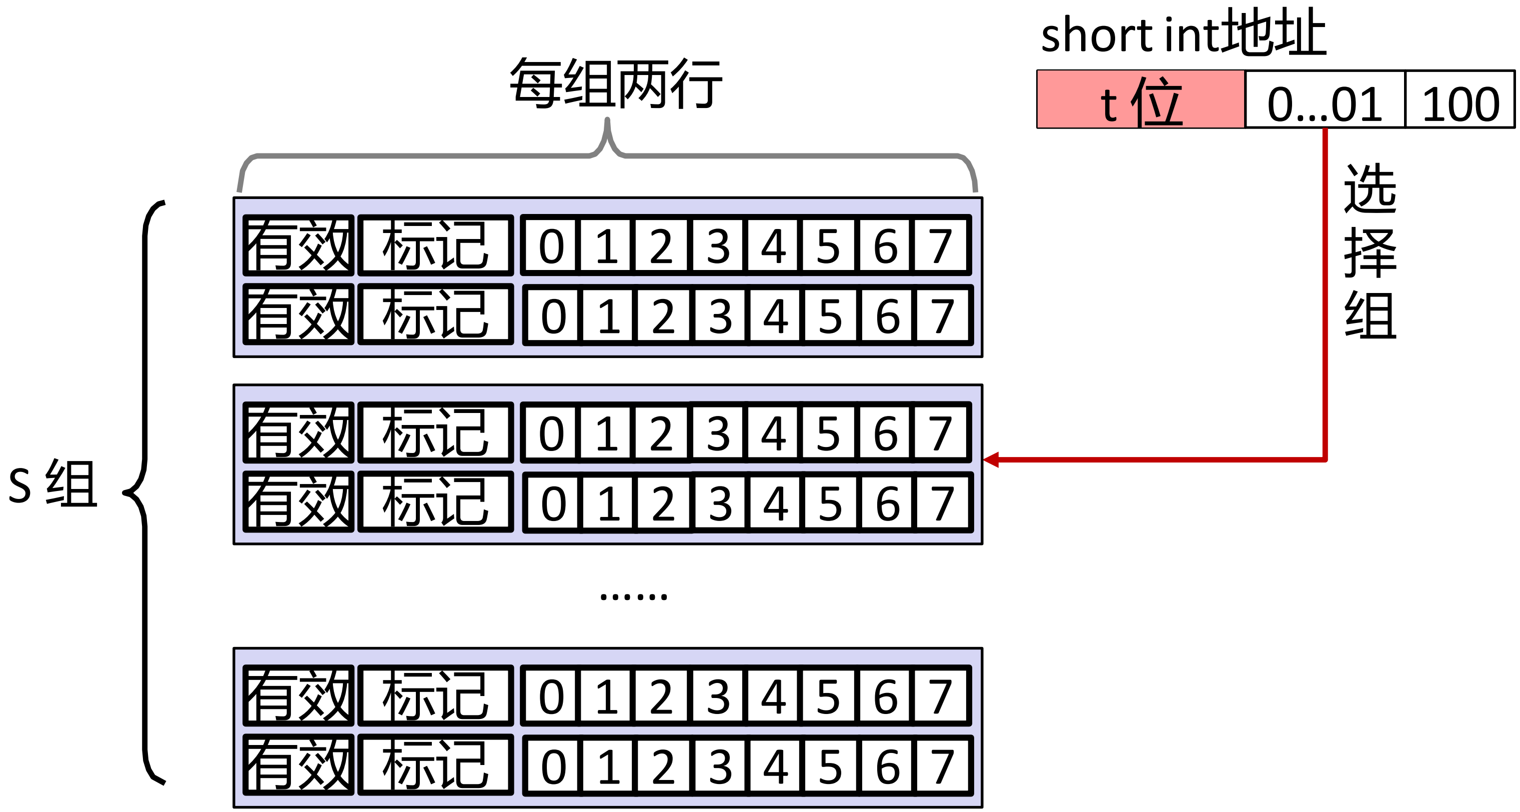

方式2： E-路组相联高速缓存(E = 2)

E = 2: 每组两行
假设:缓存块大小为8字节

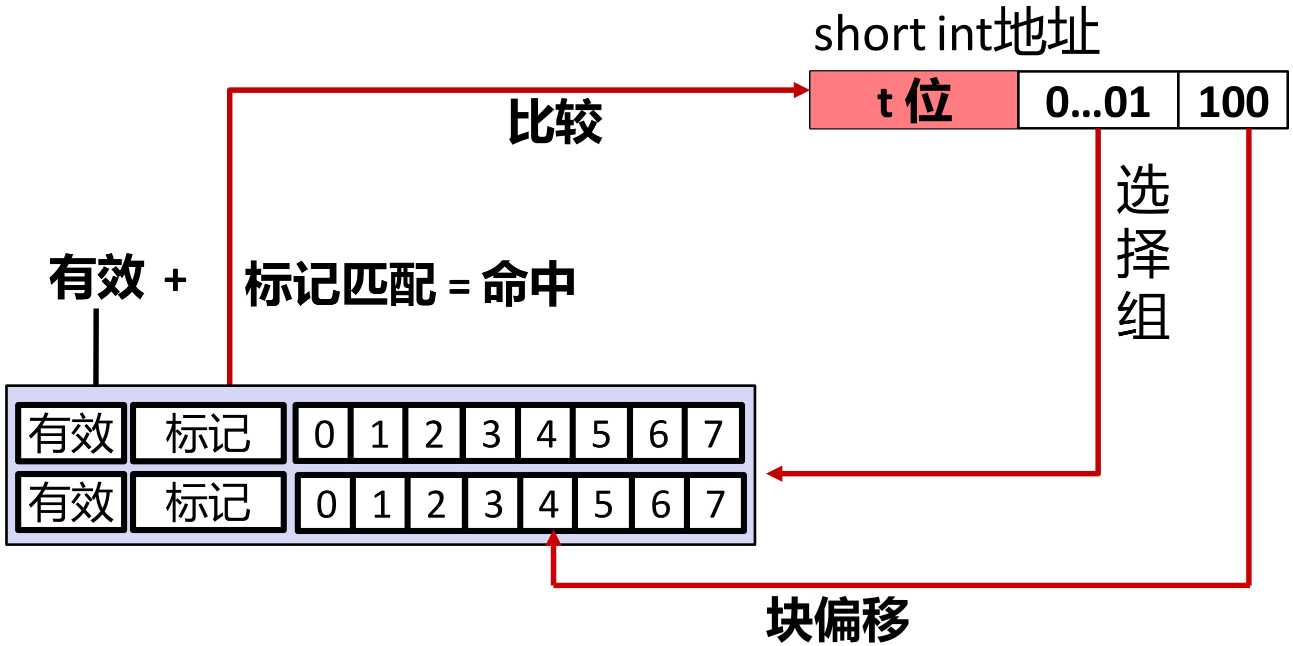

方式2： E-路组相联高速缓存(E = 2)

E = 2: 每组两行
假设:缓存块大小为8字节

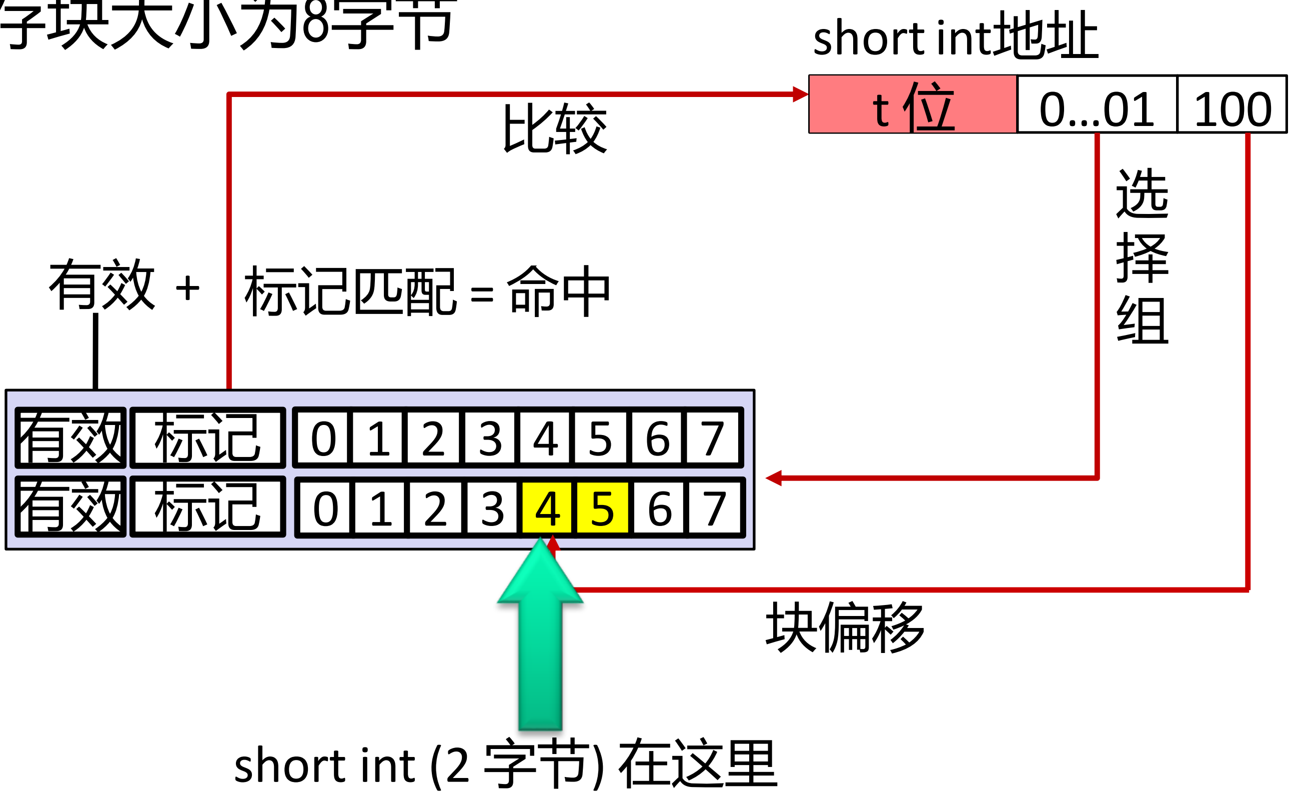

不匹配:
- 在组中选择1行用于驱逐和替换
- 替换策略: 随机、最近最少使用(LRU), …

方式2： 2-路组相联缓存模拟

t=2	s=1	b=1
xx	x	x

M=16 字节地址, B=2 字节/块, S=2 组, E=2 块/组

地址跟踪(读, 每次读一个字节):

0	$[00\underline{0}0_2]$,	miss
1	$[00\underline{0}1_2]$,	hit
7	$[01\underline{1}1_2]$,	miss
8	$[10\underline{0}0_2]$,	miss
0	$[00\underline{0}0_2]$	hit

	v	标记	块
组0	1	10	M[8-9]
	1	00	M[0-1]
组1	1	01	M[6-7]
	0	?	?

Cache的种类

- **1、直接映射：** E=1

  主存中的一个块只能映射到Cache的某一特定块。

- **2、全相联映射：** S=1

  主存中任何一块都可以映射到Cache中的任何一块。

- **3、组相联映射：** E>1 && S>1

  是前两种方法的折中方案，适度兼顾二者的优点，尽量避免二者的缺点，普遍采用。

关于怎么写?

- **存在多个数据副本:**
  - L1, L2, L3,主存, 磁盘
- **在写命中时要做什么?**
  - 直写 (Write-through，立即写入存储器)
  - 写回 (Write-back，推迟到缓存行要替换时才写入内存)
    - 需要一个修改位 (标识缓存行与内存是否相同/有修改)
- **写不命中时要做什么?**
  - 写分配 (Write-allocate加载到缓存,更新这个缓存行)
    - 如后续有较多向该位置的写，优势明显
  - 非写分配 (No-write-allocate直接写到主存中,不加载到缓存中)
- **典型方案**
  - 直写 + 非写分配
  - 写回 + 写分配

Intel Core i7高速缓存层次结构

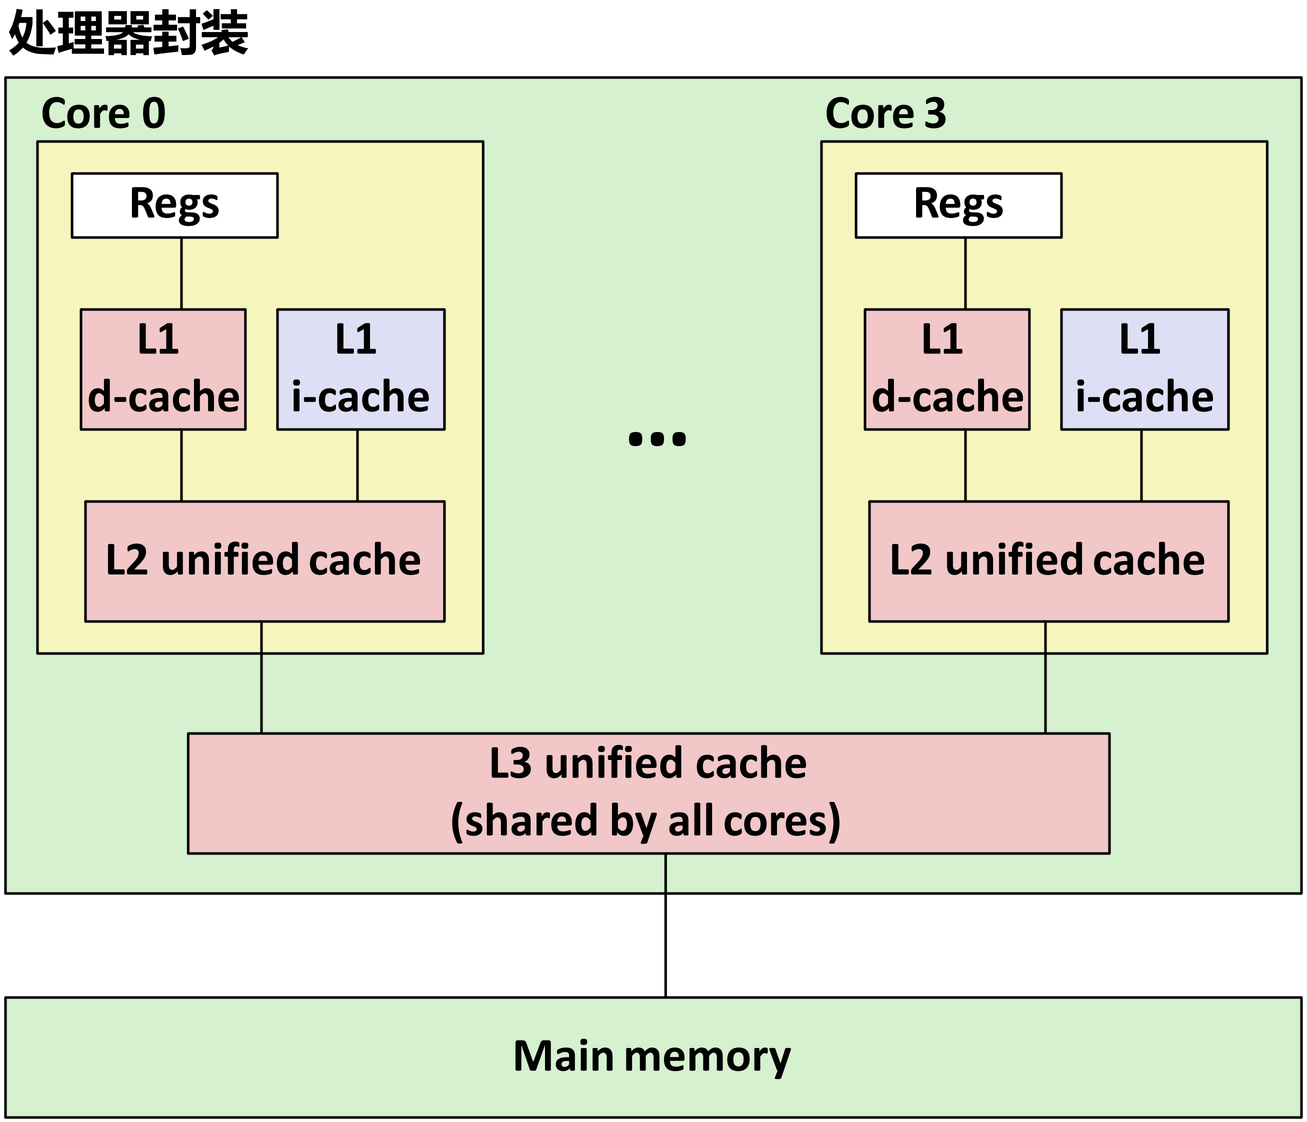

L1 指令高速缓存 和 数据高速缓存:
32 KB, 8-way,
访问时间: 4周期

L2 统一的高速缓存:
256 KB, 8-way,
访问时间: 10 周期

L3 统一的高速缓存:
8 MB, 16-way,
访问时间: 40-75 周期

块大小:
所有缓存都是64 字节

通用的高速缓存存储器组织结构(S, E, B)

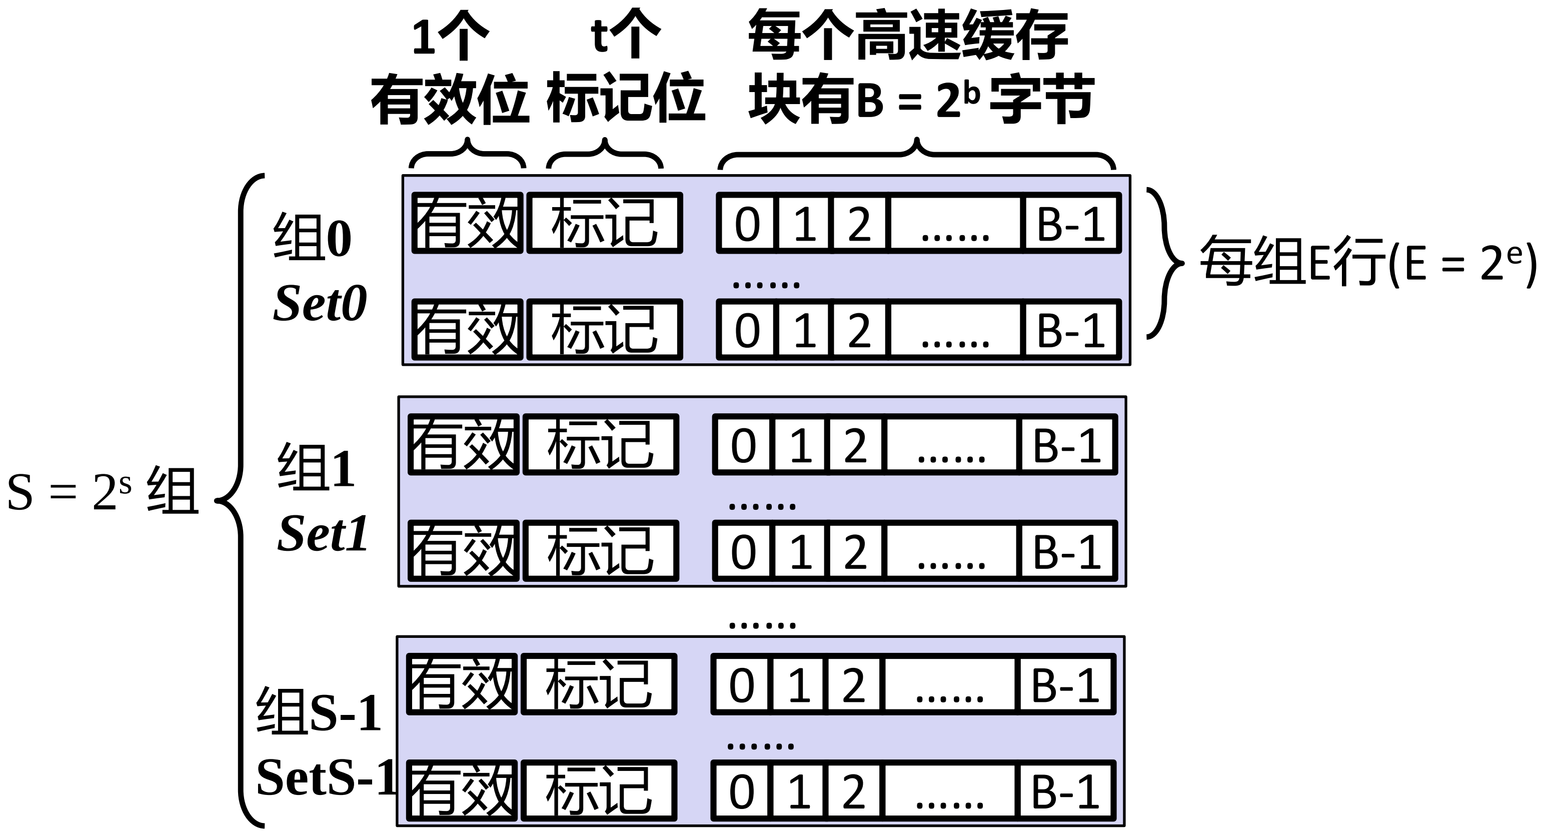

高速缓存大小 ***$C = S \times E \times B$ 数据字节***

例子: Core i7 L1 数据缓存

32 KB、8路组相联
64 字节/块
48/52 位地址范围

B =
S = s =
E = e =
C =

高速缓存大小 C = S x E x B 数据字节

Hex	Decimal	Binary
0	0	0000
1	1	0001
2	2	0010
3	3	0011
4	4	0100
5	5	0101
6	6	0110
7	7	0111
8	8	1000
9	9	1001
A	10	1010
B	11	1011
C	12	1100
D	13	1101
E	14	1110
F	15	1111

Address of word:

t bits	s bits	b bits
tag	set index	block offset

块偏移: ?位
组索引: ?位
标　记: ?位

栈地址:
0x00007f7262a1e010

块偏移: 0x??
组索引: 0x??
标　记: 0x??

例子: Core i7 L1 数据缓存

32 KB、8路组相联
64 字节/块
48/52 位地址范围

B = 64
S = 64, s = 6
E = 8, e = 3
C = 64 x 64 x 8 = 32,768

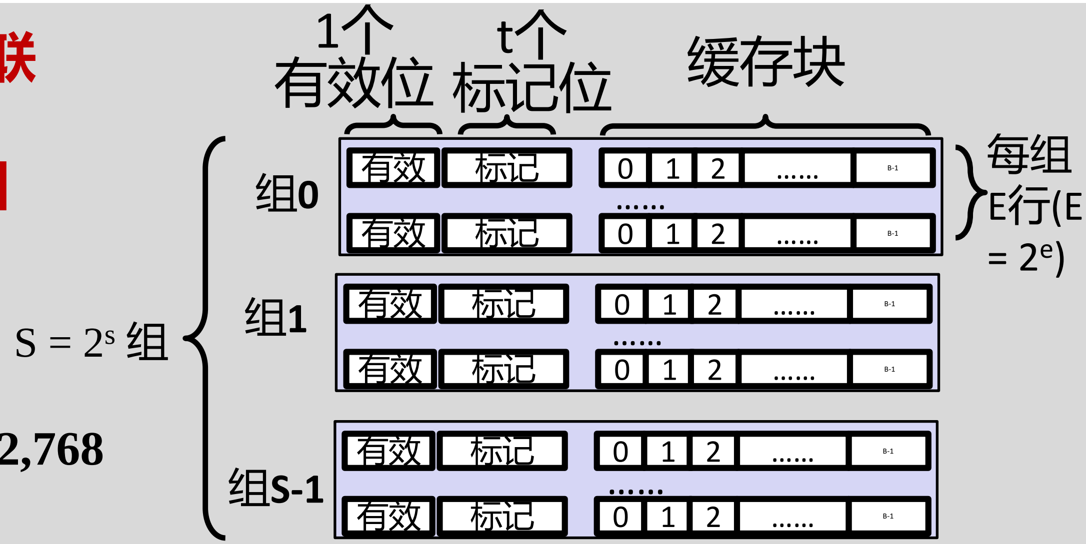

高速缓存大小 C = S x E x B 数据字节

Hex	Decimal	Binary
0	0	0000
1	1	0001
2	2	0010
3	3	0011
4	4	0100
5	5	0101
6	6	0110
7	7	0111
8	8	1000
9	9	1001
A	10	1010
B	11	1011
C	12	1100
D	13	1101
E	14	1110
F	15	1111

Address of word:

t bits	s bits	b bits
tag	set index	block offset

块偏移: 6 bits
组索引: 6 bits
标　记: 剩余全部bit
(36/40 bits)

栈地址:
0x00007f7262a1e010

0000 0001 0000

块偏移: 0x10
组索引: 0x0
标　记: 0x7f7262a1e

高速缓存性能指标

- **不命中率**
  - 一部分内存引用在缓存中没有找到 (不命中 / 访问)
    = 1 – 命中率
  - 典型数值(百分比):
    - L1： 3-10%
    - L2： 可以相当小(e.g., < 1%) ， 依赖于L2大小等因素。
- **命中时间**
  - 从高速缓存向处理器发送一行的时间
    - 时间包括判断行是否在缓存中
  - 典型数值:
    - L1 4个时钟周期
    - L2 10个时钟周期
- 不命中处罚
  - 由于不命中需要额外的时间
    - 通常主存需50-200周期(趋势: 增加！)

不命中率 VS 命中率

- **命中 or 不命中：差距巨大**
  - 如果只有L1 和 主存，那么可以差100倍
  - 你会相信99%命中率要比97%好两倍?
- **假 设**
  - 缓存命中时间为1个周期
  - 不命中处罚要100个周期
- **平均访问时间**
  - 97% 命中率：0.97*1 周期 + 0.03 x 100 周期 = 4 周期
  - 99% 命中率：0.99*1 周期 + 0.01 x 100 周期 = 2 周期
- **这就是为什么用“不命中率”而不是“命中率”**

编写高速缓存友好的代码

- 让常见的情况运行得快
  - 专注在核心函数和内循环上
- 使用内层循环的缓存不命中数量降到最低
  - 反复引用变量好(时间局部性)
  - 步长为1的引用模式好(空间局部性)
- 关键思想

局部性的定性概念是通过缓冲存储器的理解而量化

主要内容

- 高速缓存的组织结构和运算
- 高速缓存对程序性能的影响
  - 存储器山
  - 重新排列以提升空间局部性
  - 使用块来提高时间局部性

存储器山

- **读吞吐量 (读带宽)**
  - 每秒从存储系统中读取的字节数(MB/s)

- **存储器山：测量读取吞吐量作为空间和时间局部性的函数**
  - 描述存储系统性能的一种直观、紧凑的方式

存储器山测试函数

```
long data[MAXELEMS];  /* Global array to traverse */
/* test - Iterate over first "elems" elements of
 *        array “data” with stride of "stride", using
 *        using 4x4 loop unrolling.*/
int test(int elems, int stride) {
   long i, sx2=stride*2, sx3=stride*3, sx4=stride*4;
   long acc0 = 0, acc1 = 0, acc2 = 0, acc3 = 0;
   long length = elems, limit = length - sx4;
   /* Combine 4 elements at a time */
   for (i = 0; i < limit; i += sx4) {
      acc0 = acc0 + data[i];
      acc1 = acc1 + data[i+stride];
      acc2 = acc2 + data[i+sx2];
      acc3 = acc3 + data[i+sx3];
   }
   /* Finish any remaining elements */
   for (; i < length; i++) {
      acc0 = acc0 + data[i];
   }
   return ((acc0 + acc1) + (acc2 + acc3));
}
```

用多种elems、stride组合调用test()

对于每个 elems和stride:

1. 调用一次test()函数，预热缓存

2. 再次调用test() 函数，测量读操作的吞吐量(MB/s)

存储器山

Core i7 Haswell
2.1 GHz
32 KB L1 高速缓存
256 KB L2高速缓存
8 MB L3 高速缓存
64 B 块大小

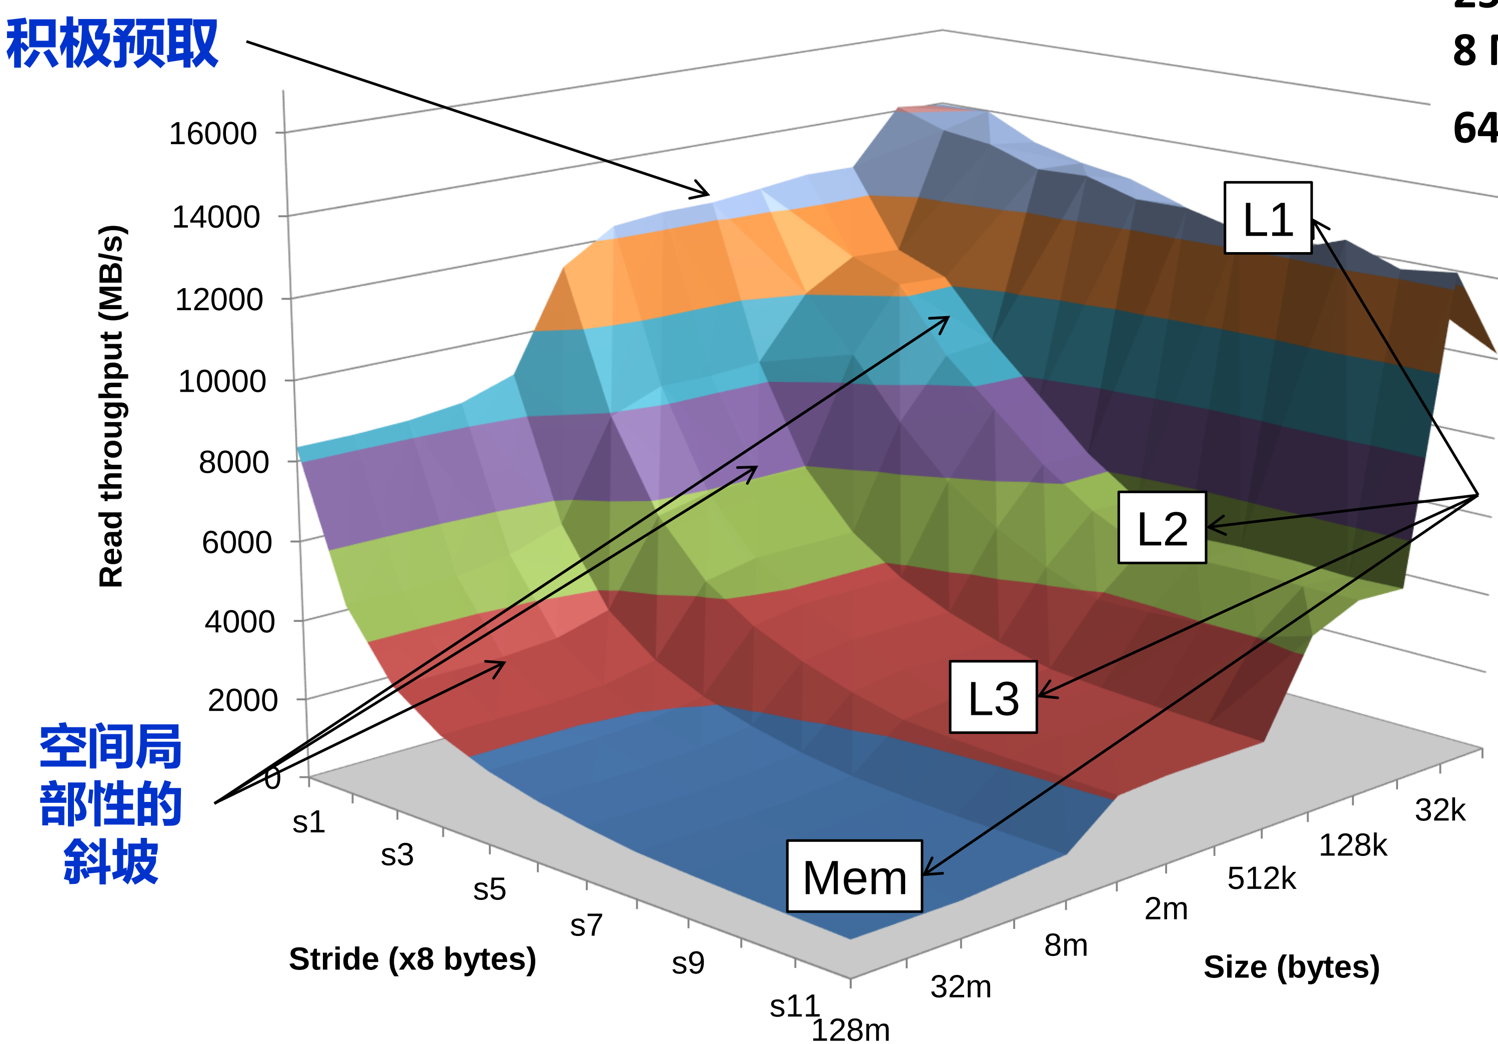

工作集大小VS缓存尺寸关系

- stride=8时，吞吐量和工作集的关系

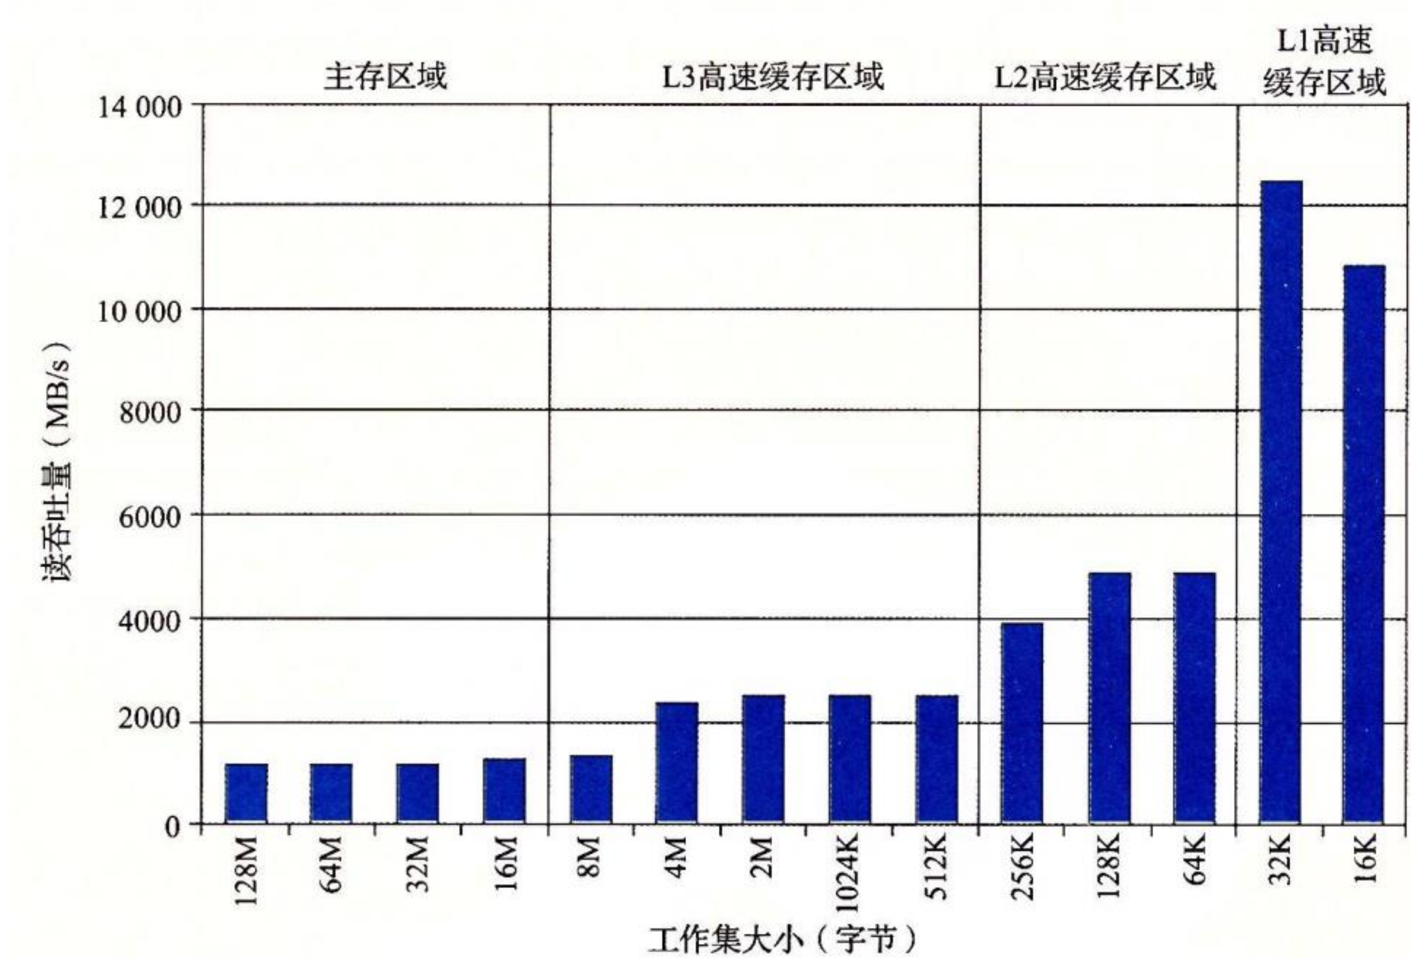

主要内容

- 高速缓存的组织结构和运算
- 高速缓存对程序性能的影响
  - 存储器山
  - **重新排列以提升空间局部性**
  - 使用块来提高时间局部性

矩阵乘法的例子

- **描述:**
  - *N* x *N* 矩阵相乘
  - 矩阵元素类型是 doubles (8 字节)
  - 总共O(N^3) 个操作
  - 每个元素都要读*N*次
  - 每个目标中都要对*N*个值求和
    - 但也可以保存在寄存器中

*变量*sum*保存在寄存器中*

```
/* ijk */
for (i=0; i<n; i++)  {
  for (j=0; j<n; j++) {
    sum = 0.0;
    for (k=0; k<n; k++)
      sum += a[i][k] * b[k][j];
    c[i][j] = sum;
  }
}
```

矩阵相乘不命中率分析

- **假设:**
  - 块大小 = 32B (足够容纳4个double数)
  - 矩阵的维数N非常大：1/N大约为 0.0
  - 缓存并未大到足够容纳多行
- **分析方法:**
  - 看内循环的的访问模式

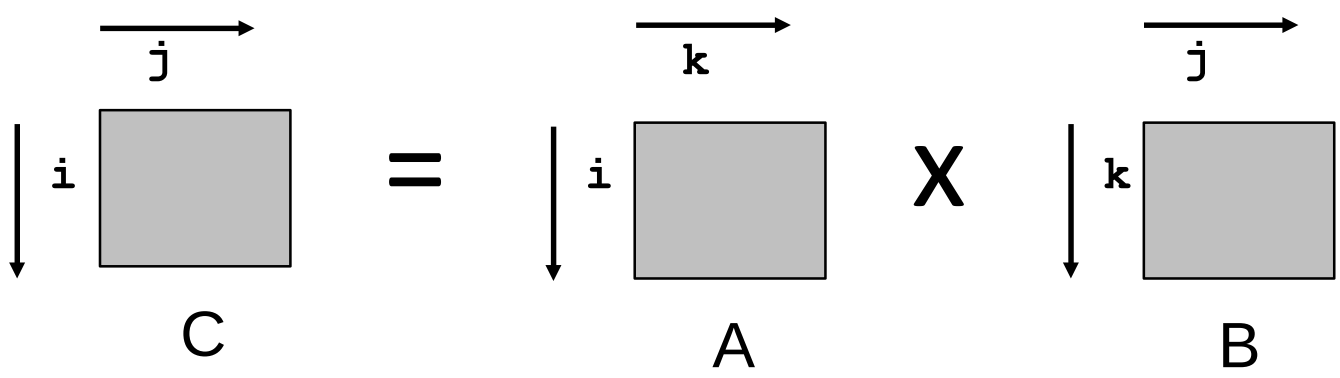

内存中C数组的布局(回顾)

- C 数组分配按行顺序
  - 每行在连续的内存位置
- 按行扫描:
  - for (i = 0; i < N; i++)
    sum += a[0][i];
  - 访问连续的元素
  - 如果块大小 (B) > sizeof(a_{ij})字节, 利用空间局部性
    不命中率 = sizeof(a_{ij}) / B
- 按列扫描:
  - for (i = 0; i < n; i++)
    sum += a[i][0];
  - 访问远隔的元素
  - 没有空间局部性!
    - 不命中率 = 1 (i.e. 100%)

矩阵乘法(ijk)

```
/* ijk */
for (i=0; i<n; i++)  {
  for (j=0; j<n; j++) {
    sum = 0.0;
    for (k=0; k<n; k++)
      sum += a[i][k] * b[k][j];
    c[i][j] = sum;
  }
}                                matmult/mm.c
```

内层循环：

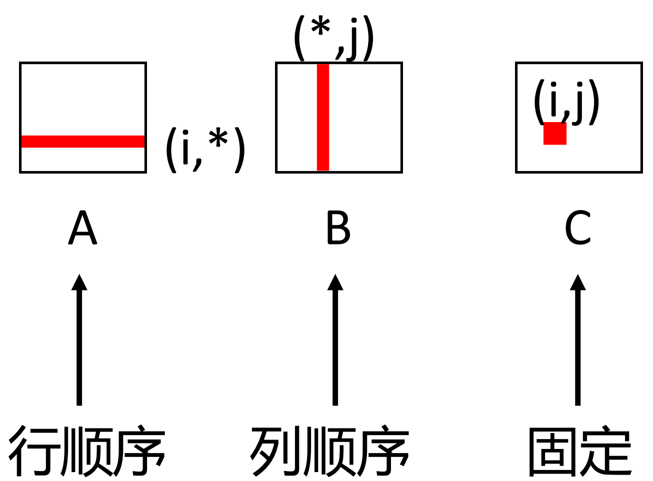

每次内层循环迭代的不命中数:

A	B	C
0.25	1.0	0.0

块大小 = 32B (4 doubles)

矩阵乘法(jik)

```
/* ijk */
for (j=0; j<n; j++) {
  for (i=0; i<n; i++)  {
    sum = 0.0;
    for (k=0; k<n; k++)
      sum += a[i][k] * b[k][j];
    c[i][j] = sum;
  }
}                              matmult/mm.c
```

内层循环:

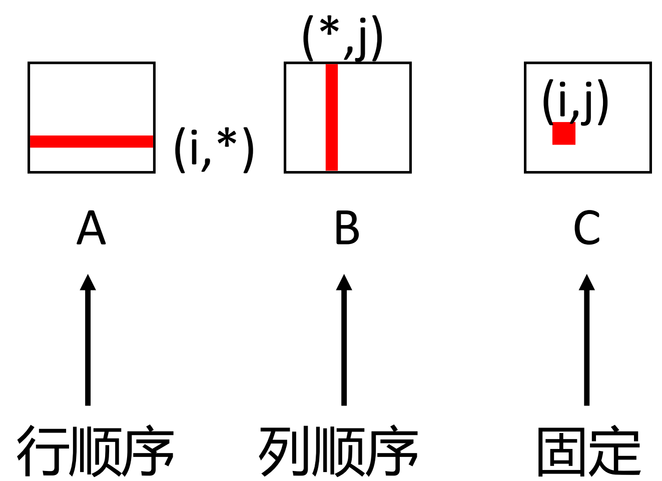

<u>每次内层循环迭代的不命中 数:</u>

<u>A</u>	<u>B</u>	<u>C</u>
0.25	1.0	0.0

块大小 = 32B (4 doubles)

矩阵乘法(kij)

```
/* kij */
for (k=0; k<n; k++) {
  for (i=0; i<n; i++) {
    r = a[i][k];
    for (j=0; j<n; j++)
     c[i][j] += r * b[k][j];
  }
}                         matmult/mm.c
```

内层循环:

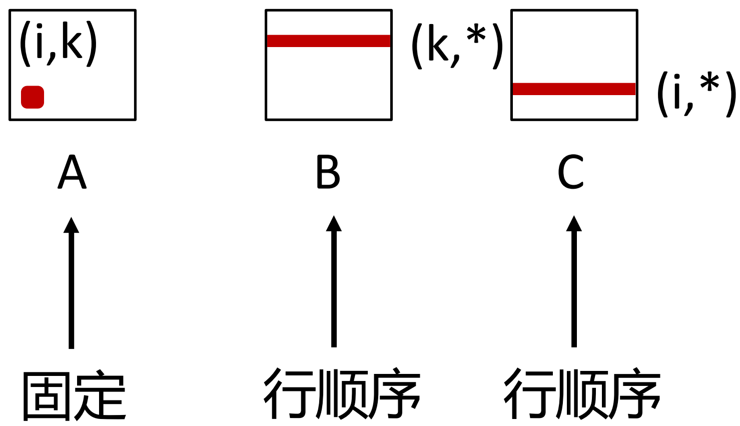

<u>每次内层循环迭代的不命中 数:</u>

<u>A</u>	<u>B</u>	<u>C</u>
0.0	0.25	0.25

块大小 = 32B (4 doubles)

矩阵乘法(ikj)

```
/* ikj */
for (i=0; i<n; i++) {
  for (k=0; k<n; k++) {
    r = a[i][k];
    for (j=0; j<n; j++)
      c[i][j] += r * b[k][j];
  }
}
                         matmult/mm.c
```

内层循环:

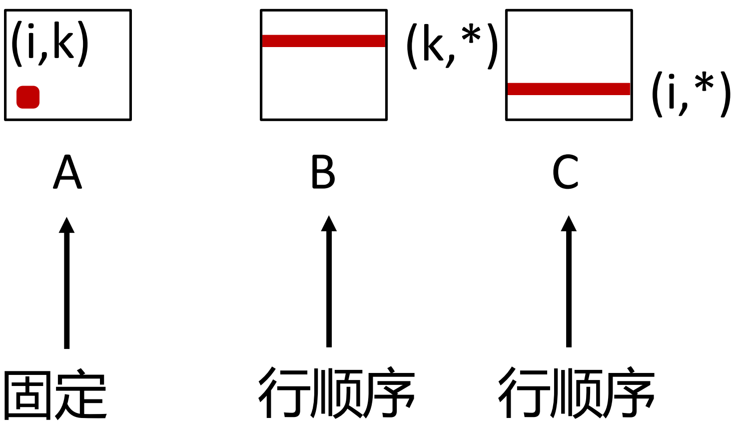

每次内层循环迭代的不命中 数:

A	B	C
0.0	0.25	0.25

块大小 = 32B (4 doubles)

矩阵乘法 (jki)

```
/* jki */
for (j=0; j<n; j++) {
   for (k=0; k<n; k++) {
     r = b[k][j];
     for (i=0; i<n; i++)
     c[i][j] += a[i][k] * r;
   }
}
```

matmult/mm.c

内层循环:

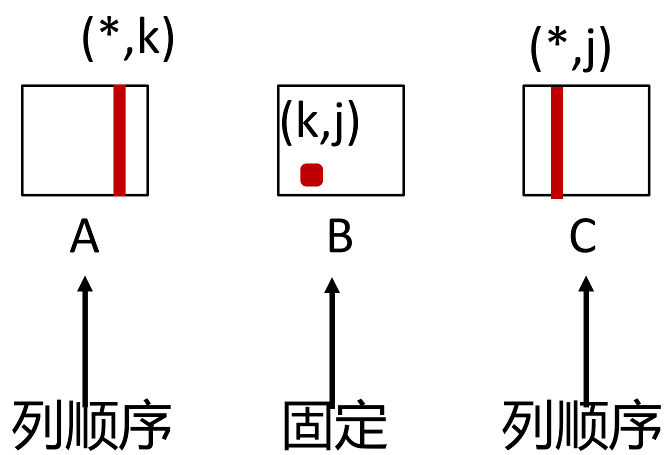

<u>每次内层循环迭代的不命中 数:</u>

A	B	C
1.0	0.0	1.0

块大小 = 32B (4 doubles)

矩阵乘法 (kji)

```
/* kji */
for (k=0; k<n; k++) {
   for (j=0; j<n; j++) {
     r = b[k][j];
     for (i=0; i<n; i++)
        c[i][j] += a[i][k] * r;
   }
}
```

matmult/mm.c

内层循环:

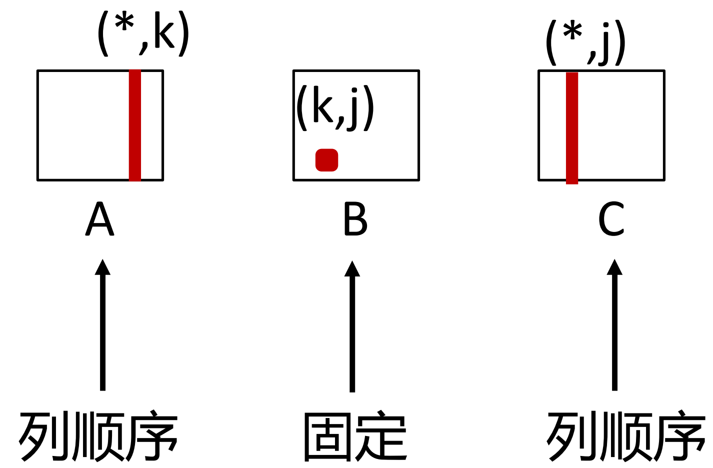

<u>每次内层循环迭代的不命中数:</u>

A	B	C
1.0	0.0	1.0

块大小 = 32B (4 doubles)

矩阵乘法总结

```
for (i=0; i<n; i++) {
  for (j=0; j<n; j++) {
    sum = 0.0;
    for (k=0; k<n; k++)
      sum += a[i][k] * b[k][j];
    c[i][j] += sum;
  }
}
```

ijk(& jik):

- 2 加载, 0 存储
- 每次迭代的不命中率= **1.25**

```
for (k=0; k<n; k++) {
  for (i=0; i<n; i++) {
    r = a[i][k];
    for (j=0; j<n; j++)
      c[i][j] += r * b[k][j];
  }
}
```

kij(& ikj):

- 2加载, 1存储
- 每次迭代的不命中率= **0.5**

```
for (j=0; j<n; j++) {
  for (k=0; k<n; k++) {
    r = b[k][j];
    for (i=0; i<n; i++)
      c[i][j] += a[i][k] * r;
  }
}
```

jki(& kji):

- 2加载, 1存储
- 每次迭代的不命中率= **2.0**

Core i7矩阵乘法性能

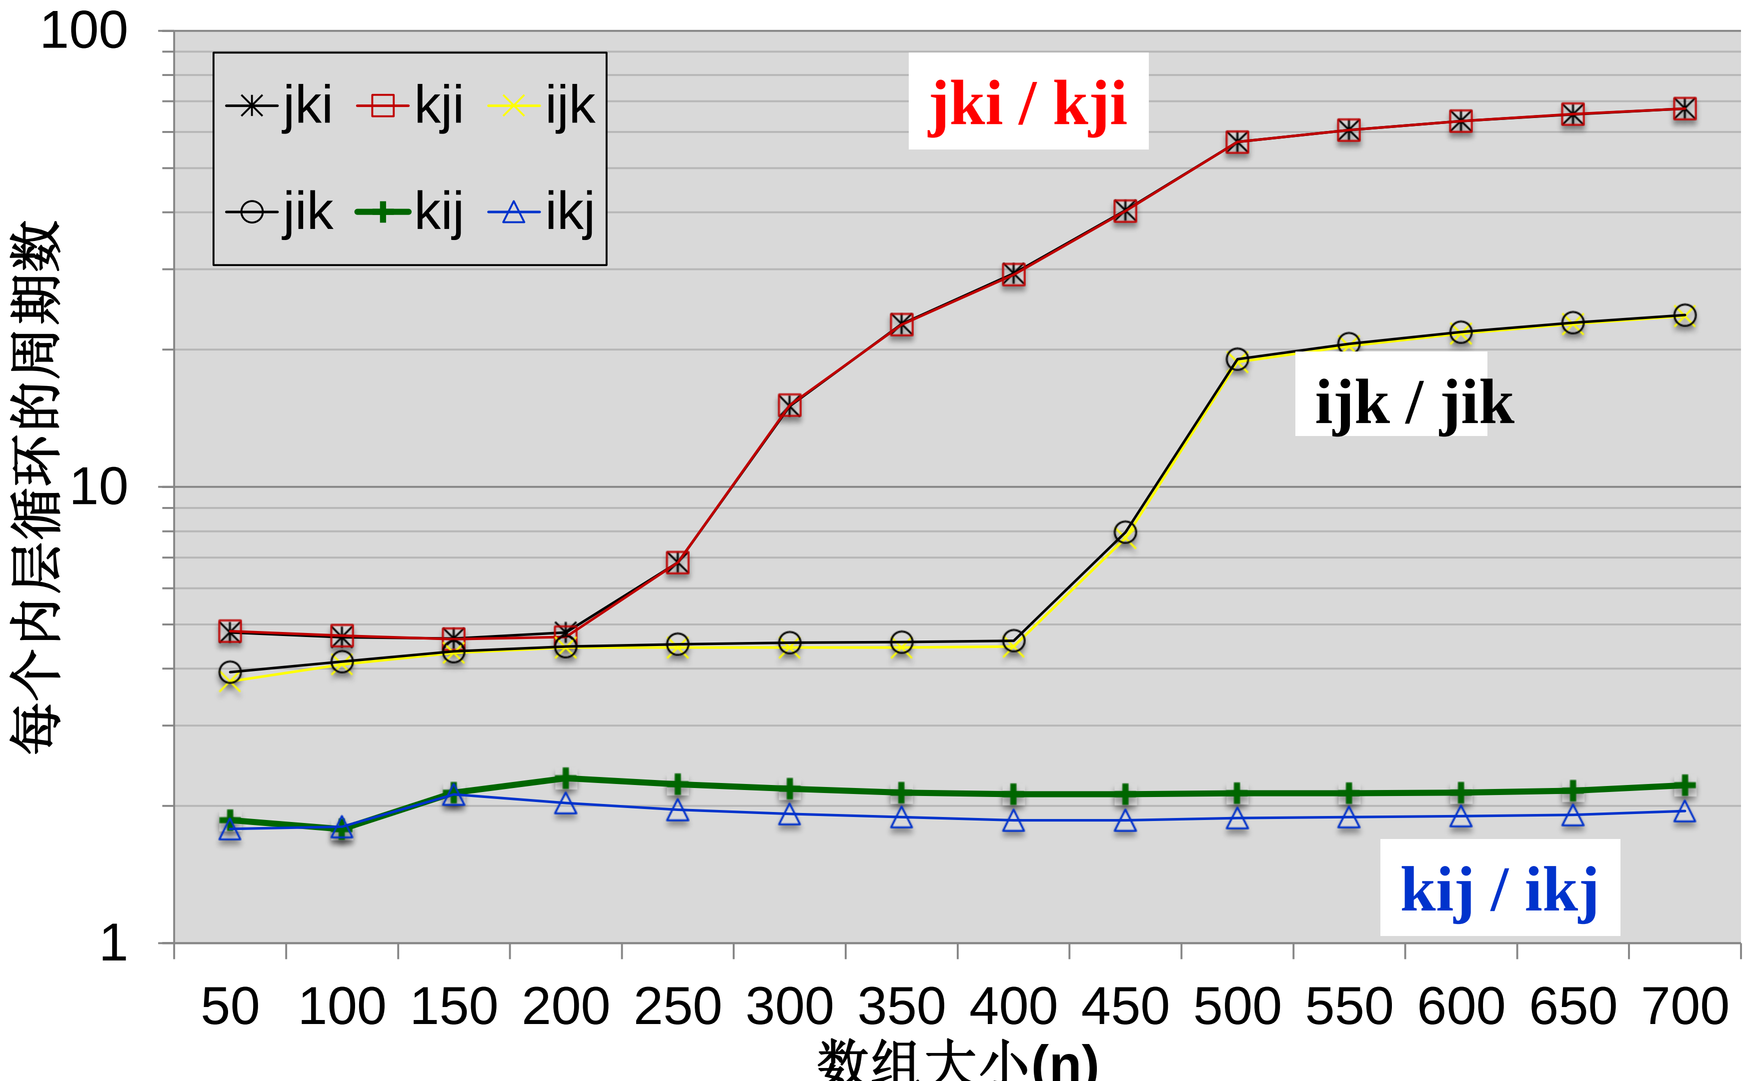

主要内容

- 高速缓存的组织结构和运算
- 高速缓存对程序性能的影响
  - 存储器山
  - 重新排列以提升空间局部性
  - **使用块来提高时间局部性**

例子:矩阵乘法

```
c = (double *) calloc(sizeof(double), n*n);

/* Multiply n x n matrices a and b           */
void mmm(double *a, double *b, double *c, int n) {
        int i, j, k;
        for (i = 0; i < n; i++)
                for (j =0; j < n; j++)
                        for (k = 0; k < n; k++)
                                c[i*n + j] += a[i*n + k] * b[k*n + j];
}
```

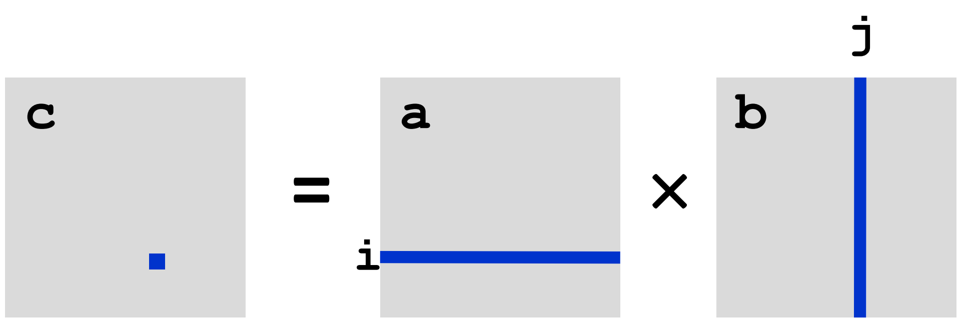

缓存不命中分析

- **假设:**
  - 矩阵元素类型是doubles
  - 缓存块 = 8 doubles
  - 缓存大小 C << *n*

- **第一次迭代:**
  - *n*/8 + n = 9*n*/8 不命中

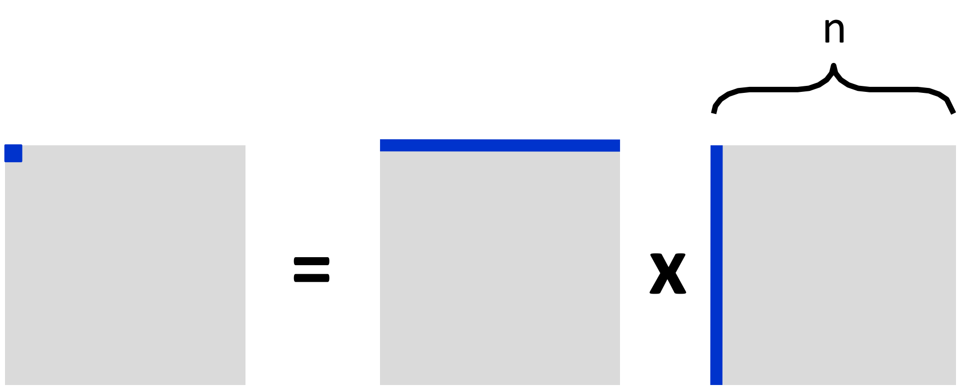

  - 第一次迭代结束时，缓存示意图

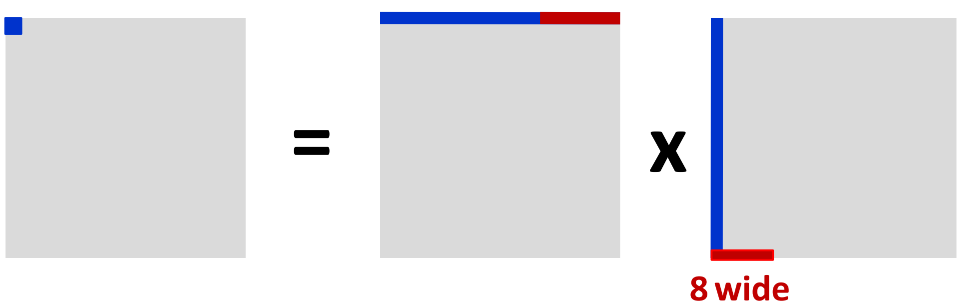

缓存不命中分析

- **假设:**
  - 矩阵元素类型是doubles
  - 缓存块 = 8 doubles
  - 缓存大小 C << *n*

- 第二次迭代:

  $\boldsymbol{n/8 + n = 9n/8}$ 不命中

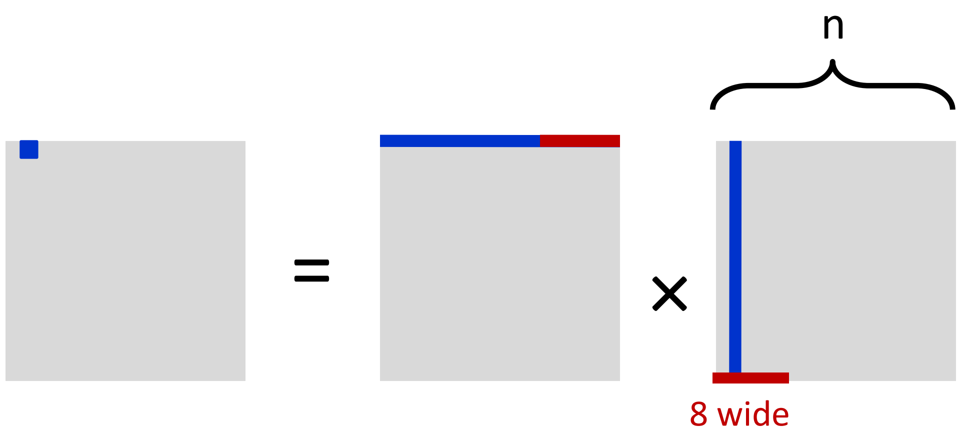

- **不命中总数:**

  $$n^2 \times 9n/8 = (9/8)\, n^3$$

分块矩阵乘法

```
c = (double *) calloc(sizeof(double), n*n);
/* Multiply n x n matrices a and b  */
void mmm(double *a, double *b, double *c, int n) {
   int i, j, k;
   for (i = 0; i < n; i+= T)
      for (j = 0; j < n; j+= T)
         for (k = 0; k < n; k+= T)
                         /* T×T mini matrix multiplications */
              for (i1 = i; i1 < i+T; i1++)
                 for (j1 = j; j1 < j+T; j1++)
                    for (k1 = k; k1 < k+T; k1++)
                         c[i1*n+j1] += a[i1*n + k1]*b[k1*n + j1];
}
```

matmult/bmm.c

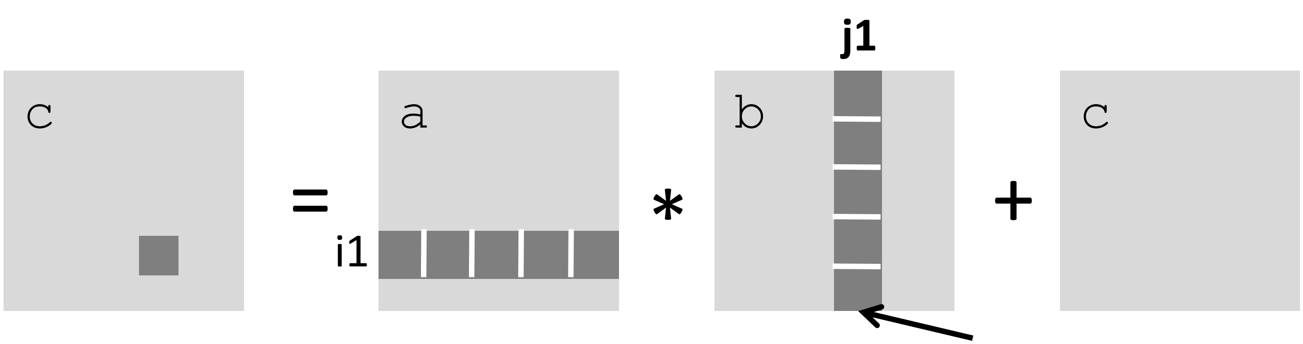

矩阵分块尺寸： T x T个数

缓存不命中分析

- **假设:**
  - 缓存块： 8 doubles
  - 缓存大小C << *n*
  - 缓存可放入三个矩阵块■ : $3T^2 < C$
- **第一次 (块) 迭代:**
  - 每块$T^2/8$个不命中,
    不命中的总数:
    $(n/T + n/T) \times T^2/8 = nT/4$
    (忽略矩阵 c)
  - 第一次迭代结束时，缓存中的块（红色）示意图

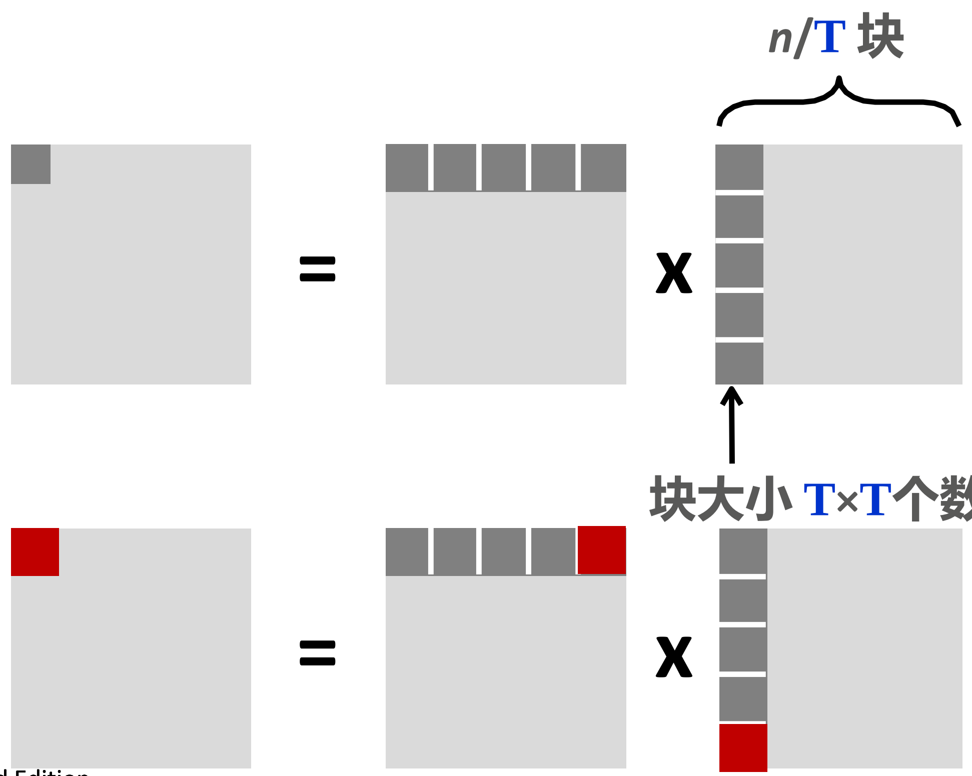

缓存不命中分析

- **假设:**
  - 缓存块： 8 doubles
  - 缓存大小C << n
  - 缓存可放入三个矩阵块 : $3T^2 < C$
- **第二次 (块) 迭代:**
  - 同第一次迭代相同，
    不命中的总数：
    $(n/T + n/T) \times T^2/8 = nT/4$

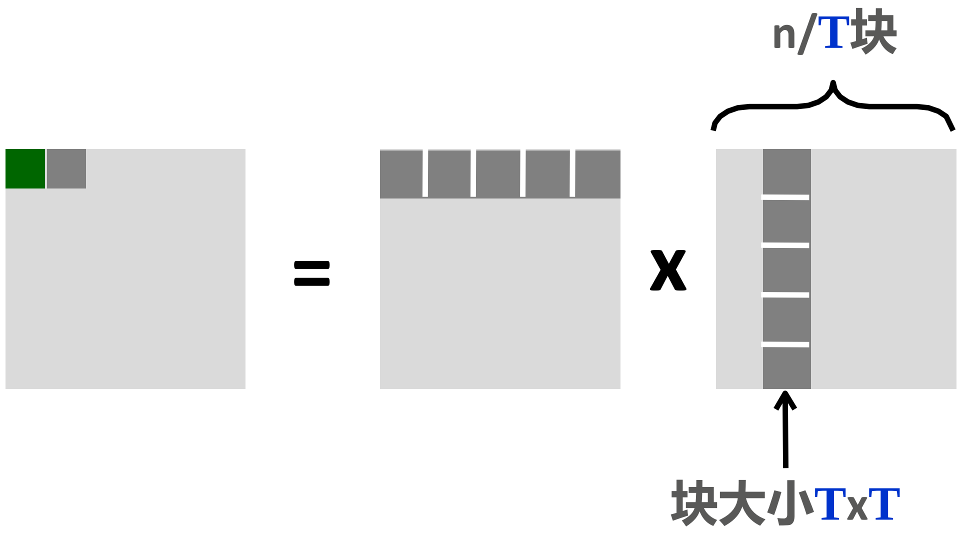

- **总不命中率:**
  - $(n/T)^2 \times nT/4 = n^3/(4T)$

分块总结

- **不分块: (9/8) n^3**
- **分　块: 1/(4T) n^3**

- **块大小T使用最大的可能值T_{max}，限制：**

  $$3T_{max}^2 < C$$

- **巨大差距的原因:**
  - 矩阵乘法有天生的时间局部性:
    - 输入数据: $3n^2$, 计算 $2n^3$
    - 每个数据组元素计算的时间复杂度（时间开销）： $O(n)$
  - 必须恰当地编写程序

高速缓存总结

- **高速缓存对程序性能有显著影响**
- **可以在程序中利用这一点!**
  - 聚焦内层循环：大部分计算和内存访问都发生在这里。
  - **最大化空间局部性**：以1为步长，按数据在内存中的存储顺序读取。
  - **最大化程序时间局部性**：从内存中读入一个数据对象后，尽可能频繁/多地使用它。